

AIOps 平台最终设计与实施规范

云平台智能运维产品 UI 数据 图谱 智能能力和验收基线

文档版本	V1.1 (自审核修订版)
目标系统	http://localhost:30253/
设计日期	2026-09-12
适用对象	产品、前端、后端、AI、测试与验收智能体
规范强度	本文的“必须 / 不得 / 应”均为可验收要求

核心产品决策

**统一账户、统一导航、统一能力可见性。系统不再拆分“值班人员端”和“管理员端”；
危险操作通过预检、影响范围、显式确认、审计与回滚进行约束。**

UI 图中的数值仅用于表达布局和异常态，不构成验收数据。验收必须连接真实环境并形成可复核的数据来源链。

文档导航

本文是实现与验收的唯一产品基线。智能体应按章节编号逐项执行，并使用 Word 导航窗格定位标题。任何偏离必须记录为设计变更，不得以“现有页面如此”作为保留理由。

章节 1—10	章节 11—附录
1 文档用途 范围和术语	11 AI 智能故障定位能力和合理性分析
2 不可变设计决策	12 真实数据 状态语义和可追溯性
3 产品能力边界与完整性模型	13 统一账户下的安全与危险操作
4 信息架构 导航和路由	14 响应式 可访问性 性能和可观测性
5 全局交互和视觉规范	15 分阶段实施任务和代码落点
6 页面级最终设计	16 完整验收门禁和交付物
7 云平台运维信息完整性	17 其他智能体的执行提示词
8 后端能力的前端归属与覆盖规则	附录 A 路由和旧入口迁移表
9 知识图谱自动更新 运维和展示	附录 B 页面级验收检查表
10 AI 能力中心	附录 C 需求追踪矩阵和最终完成定义

阅读顺序：产品/设计智能体先读 1—7；前后端智能体必须读 1—15；测试/验收智能体必须完整阅读全文。

1 文档用途 范围和术语

1.1 用途

本规范把产品目标、信息架构、页面结构、数据契约、后端覆盖、知识图谱、AI 控制面、智能故障定位、安全边界、实现顺序和验收证据固化为同一份可执行文档。它不是概念稿，也不是已有页面的评审记录，而是从零设计后的目标状态。

1.2 范围

- 覆盖目标站点所有可见页面、交互、空态、异常态、加载态、权限/范围态和真实数据展示。
- 覆盖所有公共后端能力的前端归属；内部编排与内部查询端点仅需可观测，不要求一端点一页面。
- 覆盖云平台五类运维域：计算、网络、存储、Kubernetes/容器、应用与中间件，以及它们的因果关系。
- 覆盖 LLM、Agent、Skill、Workflow、MCP、知识库、知识图谱、策略、安全、评测和运行可观测性。
- 覆盖智能故障定位从触发、证据、假设、验证、结论到建议、执行与复核的完整闭环。

1.3 术语与规范用语

术语	本规范定义
统一账户	同一已认证账户看到同一套页面与能力；不按值班人员/管理员折导航。
范围	平台、租户、集群、命名空间、服务、资源、时间窗等数据与操作边界。
问题	由告警、异常、SLO、变更或人工触发形成、需要调查与闭环的可跟踪对象。
调查	固定范围和数据版本后，收集证据、形成假设、验证因果并输出结论的运行实例。
证据	带来源、时间、范围、查询条件、摘要和可打开定位链接的不可含糊事实。
公共后端能力	面向前端或外部调用者的稳定 API；必须在页面、上下文动作或能力中心有归属。
内部能力	仅由服务间编排使用的端点；可不直接展示，但其运行健康必须可观测。
真实数据	从目标环境真实数据源读取、可回查、非前端 mock/fixture/静态构造的数据。

2 不可变设计决策

ID	决策	验收判定
D-01	统一账户；不拆值班人员与管理员产品。	任意登录后看到同一套主导航和“能力与设置”；不得出现 adminOnly 导航隐藏。
D-02	任务流优先。	主导航固定为：总览、问题、资源、调查、处置；知识、报告和能力与设置为次级入口。
D-03	AI 是上下文协作者，不是孤立聊天页。	主要页面均可拉起带范围和上下文的 AI 抽屉；AI 能力中心只负责配置、治理与运行观察。
D-04	事实、推断和建议分层。	事实显示来源；推断显示置信度与支持/反证；建议显示风险和预期效果。三者不得混排成一句无来源结论。
D-05	范围是第一等对象。	顶栏永久显示当前平台/集群/资源/时间；调查启动后冻结范围并显示快照时间与图谱 generation。
D-06	真实数据验收。	验收态禁止 mock、fixture、随机数、硬编码“健康”；所有关键数值可回查源接口或源系统。
D-07	高风险动作受控但不按角色拆分。	写操作始终显示预检、影响范围、确认、审计和回滚；AI 不得自动批准或执行。
D-08	一能力一权威入口。	旧路由可重定向，但不得形成同能力多套交互或重定向到无效 tab。
D-09	异常诚实可见。	未知、陈旧、部分、未接入、失败均为显式状态；不得以 0 或绿色掩盖。
D-10	公共后端能力必须有前端归属。	覆盖清单中每个公共 API 均映射到页面/动作/设置；内部 API 标注 API-only。

2.1 禁止项

- 不得恢复“值班人员端 / 管理员端”或按身份隐藏完整导航。
- 不得把“助手、知识、系统管理”作为互相割裂的产品孤岛。
- 不得使用前端静态 JSON、演示数字或随机数据证明真实环境通过。
- 不得把后端返回 200 视为功能完成；必须验证业务结果、前端状态、审计和回查。
- 不得提供可点击但无效果的按钮、重定向到不存在的视图、无法回退的深链。
- 不得让 LLM 直接持有基础设施凭据、绕过后端策略或执行未经确认的写操作。

3 产品能力边界与完整性模型

3.1 产品闭环

产品不是监控看板集合，而是围绕“发现—理解—定位—决策—执行—验证—沉淀”的统一运维闭环。每个阶段必须可以追溯到前一阶段，处置后必须回到原问题和调查验证结果。

阶段	核心问题	权威页面	必须产物
发现	现在最需要关注什么？	总览 / 问题	问题、严重度、范围、时间、可信状态
理解	受影响对象和上下游是什么？	资源 / 问题详情	资源身份、关系、信号、变更、影响面
定位	最可能的因果链是什么？	调查	冻结范围、证据、候选假设、反证、结论等级
决策	采取什么动作、风险多大？	调查 / 处置	动作建议、预检、风险、审批/确认信息
执行	动作实际发生了什么？	处置	确定性执行记录、标准输出、审计、回滚信息
验证	问题是否恢复、有无副作用？	处置 / 问题	前后指标、SLO、受影响范围复核
沉淀	如何让下一次更快更准？	知识 / 能力与设置	运行手册、知识、评测集、规则和工作流版本

3.2 云平台能力域

能力域	必须覆盖	不允许的降级
资产与拓扑	平台/集群/命名空间/节点/VM/网络/存储/应用身份、关系、生命周期与负责人	仅列 Kubernetes 容器；把网络、存储、硬件藏进原始 JSON
可观测信号	指标、日志、追踪、事件、告警、SLO、变更、容量	只展示图表，无原查询、时间、单位、缺口和关联
可靠性	健康、可用性、容量风险、备份/恢复状态、证书与关键依赖	以“无告警”等价于健康
连续性与生命周期	备份、恢复、灾备、升级、证书、补丁、配置漂移和变更窗口	只显示配置存在，不验证最近成功和恢复结果

能力域	必须覆盖	不允许的降级
安全与合规	漏洞、暴露面、身份范围、危险动作、凭据轮换、策略偏差和审计	用前端隐藏代替服务端控制；暴露 secret
成本与效率	成本分摊、预算、利用率、闲置、规格优化建议及其数据置信度	把估算显示为账单事实；无 scope 或价格版本
事件闭环	问题、调查、处置、审计、复盘、知识沉淀	问题和动作互不关联；执行后无法验证
智能能力	模型、Agent、Skill、Workflow、MCP、RAG、图谱、策略、评测、运行跟踪	只有聊天框和 LLM 配置
平台自身	采集、查询、对象存储、图谱、AI 编排、外部依赖、缓存和队列健康	AIOps 自身故障不可见
治理	账户、范围、凭据引用、数据外发、危险操作、安全审计	在浏览器保存密钥；依赖前端做权限判断

3.3 发布优先级

P0 是本次最终设计的发布门槛；P1 必须进入同一信息架构并显示真实接入状态；P2 可分期实现，但不得伪装为已支持。

级别	范围	门禁
P0	统一壳层、总览、问题、资源、调查、处置、真实数据语义、图谱运维、AI 故障定位、安全闭环	任何失败均阻断发布
P1	报告/知识、SLO、容量、静默、仪表盘、LLM/Agent/Workflow/MCP/RAG/评测、平台健康、备份/恢复状态、证书、配置漂移、补丁/漏洞清单	公共后端已有能力必须全部有入口；缺少数据源时显示真实未接入状态和影响
P2	灾备编排、自动补丁、FinOps 优化、外部 ITSM/On-call 联动	进入能力目录和路线图；若纳入合同或已有公共后端则提升为 P0/P1

4 信息架构 导航和路由

4.1 两层导航 不分两类用户

第一层承载高频运维任务；第二层承载低频配置、治理和平台能力。两层由工作频率区分，而不是由身份区分。所有入口对统一账户可见，后端仍根据令牌、租户和资源范围校验请求。

层级	入口	唯一职责	规范路由
主工作区	总览	全局态势、数据可信度、优先问题与能力健康	/overview
主工作区	问题	告警/异常/SLO/变更聚合为可跟踪问题	/problems
主工作区	资源	五类云资源、关系、信号、事件和操作入口	/resources
主工作区	调查	证据、假设、因果链、协作和结论	/investigations
主工作区	处置	待执行、执行中、已完成、失败、回滚和验证	/actions
次级	知识	知识源、运行手册、检索和沉淀	/knowledge
次级	报告	事件复盘、可靠性、容量和治理报告	/reports
次级	能力与设置	接入、数据图谱、AI、策略、安全和平台健康	/capabilities

4.2 顶栏与全局状态

- 左侧：页面标题和简短任务说明；不重复面包屑噪声。
- 中部：全局范围选择器，依次为平台/租户、集群、命名空间或资源、时间窗。
- 右侧：数据刷新状态、通知、帮助、统一账户菜单；不得出现角色切换器。
- 范围变化必须更新 URL、取消旧请求、清除不兼容选择，并在 300 ms 内给出加载反馈。
- 调查和处置页面显示“冻结范围”；用户改变全局范围不得悄然改变正在运行的调查。

4.3 深链与返回规则

规则	要求
URL 可复现	scope、time、tab、filter、selection 使用稳定查询参数；刷新后恢复。
资源链接	资源、证据、问题、调查、动作均使用 canonical UID；显示名变化不破坏链接。
来源返回	从问题进入资源/调查/动作时保留 source 参数和返回入口。
无效参数	显示明确的参数无效说明并回到安全默认视图；不得静默跳到无关页面。
旧路由	迁移期 301/replace 到规范路由且保留可转换参数；无法转换时显示迁移说明。

4.4 能力与设置子路由

子路由	页面	必须保留的状态
/capabilities/integrations	接入与目录	connector、scope、tab、status、runId
/capabilities/data-graph	图谱运维和浏览	tab、source、generation、resourceUid、relation、runId
/capabilities/ai	AI 能力中心	tab、model/workflow/agent/tool ID、version、runId
/capabilities/automation	策略与自动化	policy/workflow ID、version、status、runId
/capabilities/security	安全与范围	tab、scope、policy version、auditId
/capabilities/health	平台自身健康	capability、component、time、probeRunId

5 全局交互和视觉规范

5.1 视觉方向

目标是高信息密度但低认知负担的运维工作台：浅色中性背景、稳定左侧导航、内容优先、少量蓝色强调、状态色只表达状态。不得使用大面积渐变、装饰性 3D、无意义大卡片或把关键数据埋进抽屉。

项目	规范
画布	桌面基准 1440×900；侧栏 184 px；顶栏 56–60 px；内容左右内边距 24 px。
字体	中文优先 Microsoft YaHei/系统无衬线；正文 14 px，表格 13–14 px，标题 20/16 px。
颜色	主色 #245B89；正文 #111827；次要 #667085；背景 #F7F9FC；边框 #D9D9D9。
状态	严重/失败红；风险/陈旧琥珀；健康绿；未知/未接入灰；不得仅靠颜色区分。
圆角	卡片 8 px，按钮 6 px，标签 999 px；同层级保持一致。
阴影	默认无阴影；浮层和拖拽对象使用低强度阴影。
数据密度	表格行 40–44 px；关键 KPI 不超过首屏 6 个；高基数信息进入表格/详情。
图表	轴、单位、时间窗、采样/聚合、缺失段、阈值必须可见；不使用无刻度“好看曲线”。

5.2 组件与交互语义

组件	必须包含	禁止
KPI	值、单位、口径、时间窗、变化方向、状态	只有大数字；用 0 代替未知
状态标签	文本+图标/形状+颜色；可解释 tooltip	只用红绿点
数据表	排序、过滤、列设置、固定主列、分页/虚拟化、空态	横向溢出截断关键列
详情抽屉	稳定 URL、可复制链接、固定主动作、关闭后恢复列表位置	承载完整复杂工作流
确认对话框	动作、对象、范围、影响、风险、前置条件、回滚	“确定吗？”一行文字

组件	必须包含	禁止
加载态	结构骨架或明确进度、请求上下文、可取消长任务	页面空白或无限转圈
错误态	可读原因、request/run ID、重试、文档/诊断入口	展示堆栈或笼统“失败”
空态	区分真空、过滤为空、未接入、无权限、查询失败	统一显示“暂无数据”

5.3 AI 抽屉规范

- 入口在所有主页面右上固定；打开后不覆盖关键范围和主动作，桌面占宽 420–480 px。
- 上下文头必须显示：当前页面、scope、时间窗、选中对象、问题/调查 ID、图谱 generation。
- 每条 AI 结论使用“结论等级、置信度、支持证据、反证/缺口、下一步”结构。
- 证据引用必须可点击并回到具体图表区间、日志查询、追踪 span、事件或资源关系。
- 任何执行建议只可创建草稿动作；用户必须进入处置页完成预检与确认。

6 页面级最终设计

本章 UI 图是布局、层级和状态表达的强约束；文字内容和数值是示例。实现允许响应式重排，不允许改变信息优先级、页面职责或安全语义。

6.1 总览



图 1 总览：态势、真实数据可信度、优先问题与能力健康

实现与验收约束

- 首屏只回答四件事：覆盖如何、是否可信、什么最急、平台能力是否可用。
- KPI 固定为：资源覆盖、活跃问题、受影响范围、采集/查询健康；口径通过 tooltip 打开。
- 数据可信度在异常时置于 KPI 下方，不得隐藏到设置页；显示最后成功、延迟、失败来源。
- 问题列表行可直接进入问题或创建调查；能力健康可进入图谱/AI/平台健康详情。
- 不得在总览堆放独立监控小组件；详细资源和信号进入对应工作区。

6.2 问题中心




图 2 问题中心：问题聚合、信号联动与状态切换

实现与验收约束

- 问题是一级对象，不等同于一条告警；关联告警、异常、SLO、变更和人工报告。
- 默认按严重程度、影响和新鲜度综合排序；支持负责人、状态、资源域、来源和时间过滤。
- 页签包含问题、告警、异常、事件、SLO、告警规则、静默；每个入口都必须真实可用。
- 问题详情显示时间线、影响对象、相关变更、信号证据、关联调查/处置和审计。
- 告警确认、静默、关闭属于写操作，必须进入统一动作安全流程。

6.3 资源中心




图 3 资源中心：云平台五域统一资源视图

实现与验收约束

- 一级资源域固定为计算、网络、存储、Kubernetes、应用；不以采集器或后端服务划分。
- 所有资源使用 canonical UID；名称只是展示字段，详情须显示集群、命名空间、来源与时间。
- 详情分为概览、关系、指标、日志、追踪、事件、变更、问题、动作；缺少来源时显示未接入。
- 拓扑从资源详情按需打开，避免默认渲染全图；默认两跳、可限制关系类型和时间。
- 容量、硬件、虚拟机、网络设备和中间件不得依赖失效重定向或原始 JSON 才能访问。

6.4 调查工作台




图 4 调查工作台：冻结范围、步骤、证据与假设

实现与验收约束

- 进入调查后冻结 scope、时间窗、资源集合和图谱 generation，所有查询继承该上下文。
- 左栏是步骤与运行进度；中栏是可验证证据；右栏是候选假设、支持/反证和结论等级。
- 允许人工补充证据、驳回假设、调整时间窗并生成新版本；旧版本不可被覆盖。
- 长任务显示阶段、最近进度、已用时间、可取消；首次可见进度 p95 不超过 10 秒。
- 结论不足时必须停在 Unknown/Candidate/Supported，不得为了完整感输出 Confirmed。

6.5 处置中心




图 5 处置中心：动作生命周期、预检和恢复验证

实现与验收约束

- 动作状态固定：Draft → Preflight → Awaiting confirmation → Running → Succeeded/Failed → Verified/Rolled back。
- 每条动作显示对象、范围、来源调查、风险等级、创建者、执行器、时间、标准输出摘要和审计 ID。
- 预检验证资源身份、当前状态、依赖、幂等键、并发冲突、维护窗口和回滚可用性。
- 执行完成不等于恢复；必须回到问题指标/SLO 对比动作前后并形成验证结论。
- 批量动作在确认前显示逐对象影响；部分失败要可重试成功子集以外的对象。

6.6 上下文 AI 助手



图 6 上下文 AI：在当前任务中解释证据和建议下一步

实现与验收约束

- AI 默认继承当前页面上下文，不要求用户重复描述集群、资源和时间。
- 回答按“摘要—结论等级—证据—反证/缺口—下一步”呈现；证据数量与来源清晰可见。
- 对话可升级为调查，或把建议保存为动作草稿；不得从聊天消息直接执行基础设施写操作。
- 显示模型/路由、工作流版本、工具调用数、知识版本和 run ID，以支持复现与评测。
- 工具错误、超时或部分数据必须进入回答，不得被模型文本掩盖。

6.7 能力与设置总览



图 7 能力与设置：接入、图谱、AI、策略、安全与平台健康

实现与验收约束

- 一级卡片固定：接入与目录、数据与图谱、AI 能力中心、策略与自动化、安全与范围、平台自身健康。
- 卡片必须同时展示配置状态、运行状态、最后变更、负责人/来源和进入详情的主动作。
- 健康摘要不能只看配置存在；必须结合探测、最近运行、错误率和依赖可用性。
- 密钥只显示引用和轮换状态；任何明文 secret 都不得返回浏览器。
- 配置变更必须有校验、差异预览、版本历史、回滚和审计。

6.8 图谱运维




图 8 图谱运维：自动更新、来源质量、版本与对账

实现与验收约束

- 来源表必须展示 enabled、cadence、last attempted、last success、duration、quality、generation、error。
- 分别表达采集/读取、投影、写入、对账、发布五阶段；“调度成功”不能代表“图谱可用”。
- 支持按来源重跑、查看差异、冻结/解冻、查看 schema/alias、跳转到失败运行；写动作进入安全确认。
- 图谱状态要在资源和调查页面被消费；仅在设置页展示任务表仍不算前端覆盖。
- 原始 JSON 保留为诊断附属视图，不能作为主要产品界面。

6.9 AI 能力中心




图 9 AI 能力中心：模型、Agent、Workflow、MCP、知识与评测

实现与验收约束

- 导航固定为模型与路由、Agent 与 Skill、Workflow、MCP 与工具、知识与 RAG、策略与安全、评测与运行。
- 工作流必须显示触发器、节点、输入输出 schema、超时/重试、工具风险、发布版本和运行历史。
- MCP 必须展示 server 健康、transport、版本、工具 schema、风险级别、允许范围和最近调用。
- LLM 配置必须展示 provider/model/路由/回退/超时/成本与数据外发策略；endpoint/secret 受保护。
- 评测应绑定工作流、模型、知识和图谱版本，支持与生产 run 比较。

6.10 接入与目录




图 10 接入与目录：连接、探测、同步、覆盖和身份归一

实现与验收约束

- 连接配置和运行健康必须分开显示；配置存在但真实探测失败时状态为 Failed 或 Partial。
- 每个连接器显示 scope、认证引用、同步模式、最近尝试、最近成功、覆盖率、错误和受影响能力。
- 云平台、集群、硬件、网络、存储、应用服务和负责人目录均归一为 canonical UID。
- 凭据只显示引用、轮换日期和使用范围；浏览器不得接收原值或完整连接字符串。
- 添加、启停、重试和删除接入属于受控变更，必须有校验、影响预览、审计和恢复方法。

6.11 知识图谱浏览



图 11 知识图谱浏览：有限子图、来源、时间和 generation

实现与验收约束

- 默认从资源、问题或调查上下文进入，两跳且有节点上限；禁止首次打开无边界全图。
- 节点和关系显示类型、方向、有效时间、来源、generation 和质量，不以装饰性连线替代语义。
- 支持关系过滤、共同依赖、路径查询、影响分析和 generation 对比；所有查询可复制和复现。
- Partial、Stale 或来源缺失必须显示对结论的影响，并阻止 AI 将相关假设提升为 Confirmed。
- 固定为调查证据时保存子图查询、返回 ID 集、generation 和图谱质量快照。

6.12 知识中心




图 12 知识中心：来源、索引、运行手册、检索验证和调查沉淀

实现与验收约束

- 知识源、运行手册、索引任务、检索验证和待审阅沉淀分别有稳定页签与深链。
- 每个来源显示 owner、scope、版本、新鲜度、索引状态、文档和分块计数、错误及删除状态。
- 引用必须打开到原文和版本；仅返回文档标题或生成的摘要不算有效引用。
- 调查沉淀先进入草稿和审阅流程，发布后生成新知识版本；不得自动污染生产知识库。
- 删除必须验证索引、缓存、向量库和后续检索均不可再命中，同时保留合规审计。

6.13 报告中心




图 13 报告中心：事件、可靠性、容量、治理和数据可信度

实现与验收约束

- 报告类型固定包含事件复盘、可靠性、容量、治理审计、数据可信度和自定义仪表盘。
- 每份报告绑定 scope、时间窗、查询合同、数据版本和生成 run ID；陈旧或部分数据必须写入报告。
- 页面、PDF/CSV 导出和 API 使用同一聚合及单位；导出结果需自动对账关键数值。
- 生成、取消、失败重试、下载和保留期必须可见；长任务显示阶段和最近进度。
- 报告中的问题、资源、调查、动作和证据均提供稳定深链，不复制成无法回查的静态结论。

6.14 策略与自动化




图 14 策略与自动化：版本、运行、影响和确定性门禁

实现与验收约束

- 确定性运行策略与 AI 策略分层：本页负责告警、SLO、调查触发、处置安全和计划任务，AI 中心负责提示、工具和内容安全。
- 每个策略显示稳定 ID、类型、owner、版本、草稿/校验/发布状态、作用范围、优先级和冲突处理。
- 自动化运行显示触发器、计划、输入、run ID、阶段、重试、结果、影响和审计；可取消任务必须提供取消入口。
- 包含写操作的自动化默认关闭，发布前必须 dry run、权限测试、失败注入、幂等和恢复验证。
- AI 只能提供候选参数或草稿，最终执行必须通过本页展示的确定性策略与处置安全流程。

6.15 安全与范围




图 15 安全与范围：统一能力可见性和服务端策略

实现与验收约束

- 统一账户看到完整页面和能力；服务端根据已验证身份、租户、集群、资源和动作风险计算授权。
- 页面显示当前有效 scope、策略版本、最近验证、拒绝原因和诊断 ID，不暴露其他租户的存在或数据。
- 凭据引用、轮换、使用者和过期状态可见；secret、token 和完整 endpoint 不进入浏览器或 AI 上下文。
- R2/R3 动作的预检、确认、幂等、审计和恢复要求可直接查看，并与处置页使用同一策略版本。
- 数据外发、MCP、知识检索和 LLM 工具调用均可按 run ID 追溯到 scope 与策略判定。

6.16 平台自身健康




图 16 平台自身健康：端到端能力链、真实探测和用户影响

实现与验收约束

- 按用户能力而不是 Pod 或容器名称组织；技术组件作为下钻信息，不能取代能力状态。
- 配置状态、真实探测、最近成功、延迟、错误率、依赖和用户影响必须同时展示。
- 端到端探测覆盖采集→查询→图谱→AI→证据归档，并生成可打开的 trace/request/run ID。
- 平台自身异常可创建问题并进入调查；不得因 AIOps 故障而只显示空白或健康绿色。
- 恢复验证、告警、容量、备份和升级状态必须可追溯到相应运行记录。

6.17 跨页面主流程

起点	主动作	目标	必须携带
总览	调查高优先级问题	问题详情/新调查	scope、time、problemId、来源 KPI
问题	开始调查	调查	问题快照、关联信号、资源、变更
资源	分析异常	调查	resourceUid、两跳关系、选中时间区间

起点	主动作	目标	必须携带
调查	创建动作草稿	处置	investigationId、 hypothesisId、evidencelds、 建议
处置	验证恢复	问题/调查	actionId、前后时间窗、验证结果
调查/处置	沉淀知识	知识	脱敏证据、结论、动作、效果、适用范围

7 云平台运维信息完整性

7.1 资源身份与关系

域	至少支持的对象	关键关系
计算	物理机、节点、虚拟机、实例、GPU/加速卡、宿主机池	hosts、runs_on、allocates、backs、depends_on
网络	区域/VPC、子网、IP、网卡、LB/Ingress、路由、交换机、端口	connects、routes_to、exposes、fronts、attached_to
存储	磁盘、卷、PVC/PV、存储池、CSI、对象存储、快照/备份	mounts、claims、provisions、replicates、backs_up
Kubernetes	集群、namespace、node、workload、pod、container、service、CRD	owns、schedules、selects、serves、controls
应用	服务、实例、API、数据库、中间件、依赖、版本、负责人	calls、reads、writes、depends_on、owned_by

7.2 信号与运维上下文

信息	展示要求	关键质量信息
指标	趋势、阈值、异常区间、对比、下钻原查询	单位、聚合、步长、缺失、source timestamp
日志	结构化字段、模板聚类、上下文、关联 trace/resource	时间偏差、截断、采样、查询范围
追踪	服务图、关键路径、错误 span、依赖延迟	采样率、trace 完整性、时钟偏差
事件	K8s/基础设施/平台事件统一时间线	来源、对象 UID、去重规则、保留期
变更	部署、配置、镜像、扩缩、网络/存储变更	操作者、版本、diff、开始/结束、回滚
告警	规则、实例、分组、确认、静默、状态历史	规则版本、评估时间、标签、缺失数据策略
SLO	SLI、目标、误差预算、燃烧率、受影响服务	窗口、有效数据、排除规则、计算版本
容量	使用、分配、请求、限制、预测、耗尽时间	预测方法、置信区间、异常值与数据缺口

7.3 完整性状态

每个资源域和信号域都必须计算并显示覆盖状态，而不是只显示已有数据。状态枚举固定如下：

状态	含义	UI 与行为
Healthy	当前窗口内采集、查询和映射均满足契约	绿色+文字；可继续下钻
Partial	有数据但范围、字段或关系不完整	琥珀色；列出缺口与影响
Stale	最后成功早于规定新鲜度	琥珀色；显示最后成功和应有频率
Unknown	无法证明健康或失败	灰色；不得转换为 0
Not connected	未配置或源系统不可达	灰色；提供接入/诊断入口
Failed	已尝试且失败	红色；显示阶段、错误、run/request ID 和重试

8 后端能力的前端归属与覆盖规则

8.1 覆盖分类

分类	含义	示例
A 页面	有权威页面、列表/详情、状态与动作	集群/资源、问题、调查、处置、图谱运维
B 上下文	嵌入资源/问题/调查而不单独建页面	指标、日志、追踪片段、拓扑两跳、容量摘要
C 能力与设置	低频配置、治理、版本和运行观察	LLM、Agent、Skill、Workflow、MCP、接入、安全
D API-only	服务间内部能力，不暴露给用户	/internal/v1/query/*、control-plane、security replay

覆盖完成的定义：每个公共 endpoint 归入 A/B/C，且从 UI 可到达、可操作、可显示成功/空/部分/失败、可回查业务结果。仅存在前端 client 方法、路由或按钮不算覆盖。

8.2 当前公共能力的目标归属

后端能力族	目标入口	目标表现	实施判定
auth/users/tenants	顶栏账户 / 安全与范围	账户、会话、租户与范围；统一账户不等于无后端授权	保留认证；移除角色拆导航
clusters/resources/services	资源	五域目录、详情和关系	所有 canonical UID 可深链
metrics/logs/traces/topology	资源/问题/调查上下文	信号证据与下钻	无孤立遥测入口
capacity/dashboards	总览/资源/报告	容量风险和可观测视图	修复失效 view 参数
alerts/rules/events/silences/SLO	问题	统一信号页签和生命周期	所有页签可真实操作
AI chat/runs/actions/shell/suggestion/nl2sql	AI 抽屉/调查/处置	运行、证据、工具与动作草稿	禁止聊天直写
skills/agents/rules/flows/workflows	AI 能力中心	定义、版本、发布和运行	不得只存在 API client
knowledge	知识 / AI 能力中心	源、索引、检索、引用与沉淀	版本和新鲜度可见
KG	资源/调查 + 数据与图谱	业务消费与运维控制面	替换 raw JSON 主视图
MCP	AI 能力中心	server、tools、权限、风险、调用记录	补齐注册表/健康等缺失契约

后端能力族	目标入口	目标表现	实施判定
IPMI/node/SNMP/ops	资源/处置	硬件、节点、网络设备和安全动作	一等页面而非失效 redirect
system health/cache/components	总览/平台自身健康	端到端能力健康和依赖	按能力而非容器名表达

8.3 新增和扩展能力的处理

- 前端发现后端缺少支持目标设计的字段或端点时，必须生成 gap 条目：能力、用户价值、请求/响应 schema、风险、测试和 owner。不得前端伪造。
- 若当前后端缺少 MCP server 注册表、运行健康、工具风险、调用审计、AI 评测集与结果、知识索引任务或工作流 DAG 版本，应将缺口列为 P1 后端工作。
- 备份/灾备、证书、配置漂移、补丁/漏洞、FinOps 等扩展云运维能力若不在后端，应在能力目录显示 Not connected/Planned，并由产品范围决定是否提升为发布门槛。

8.4 能力覆盖账本

后端覆盖不能只扫描 REST 路由。实施智能体必须生成可机器校验的能力覆盖账本，并将查询、写操作、事件流、异步任务、定时任务、导出和回调统一映射到用户可见结果。

接口形态	必须登记	完成判定
REST 或 GraphQL	method/path 或 operation、服务、schema、错误、认证、scope	A/B/C 页面可达且成功、空、部分、失败、禁止状态均有测试
SSE 或 WebSocket	channel、事件类型、顺序、心跳、断线恢复、scope	UI 可显示增量进度并处理重复、乱序、断开和恢复
异步任务	create/status/cancel/result、run ID、重试、保留期	创建后可追踪、取消、恢复、回查结果和失败阶段
定时或对账任务	schedule、owner、checkpoint、last attempted/success、影响	能力与设置可观察，失败能关联业务影响和重跑
导出或下载	生成接口、文件格式、数据版本、过期、审计	导出与页面口径一致，链接受 scope 约束并可失效
Webhook 或回调	来源、签名、幂等、重放、失败队列、目标能力	事件结果在问题、调查或处置可见，伪造与重复回调被拒绝
内部服务能力	调用方、被调用方、SLO、错误、追踪和用户影响	归入 D 类但在平台自身健康中可观测，不要求一端点一页面

账本每行至少包含 capability_id、interface_id、transport、producer、consumer、A/B/C/D 分类、UI route、触发交互、scope、风险级别、状态覆盖、测试 ID、证据位置和 owner。CI 必须阻止未分类的公共能力、失效 UI 入口和没有测试证据的覆盖声明。

9 知识图谱自动更新 运维和展示



图 17 知识图谱自动更新与消费能力图

9.1 自动更新机制的目标语义

现有系统具备图谱源调度与 generation 机制，但“有 scheduler”不等于“产品已具备可靠自动更新”。目标闭环必须覆盖调度、源读取、完整性校验、身份归一、批量写入、陈旧标记、对账、质量发布和业务消费。

来源	基准 cadence	最低质量门槛	主要消费
Outbox	2 秒	事件顺序、幂等、积压可观测	资源实时关系
Kubernetes	300 秒	canonical 完整；partial 必须阻断健康发布	K8s 资源/调度因果
KubeVirt	60 秒	VM/实例/节点映射完整	计算域
Hardware	600 秒	资产身份、传感器、节点关联	计算/硬件健康
Trace	60 秒	服务/实例映射、采样质量	应用依赖/调查
Middleware	60 秒	实例、端点、依赖、版本	应用域
Network	300 秒	设备/接口/IP/路径身份	网络域
Catalog/Change	3600 秒	目录与变更审计完整	负责人、变更因果

9.2 图谱运行状态合同

字段	要求
source	稳定来源 ID；显示名可国际化。
enabled/cadence	实际运行配置，而非前端常量。
last_attempted_at / last_success_at	同时显示；用于区分未运行、连续失败和陈旧。
stage	read / validate / normalize / project / reconcile / publish。
quality	healthy / partial / stale / failed / unknown，并包含原因和缺失统计。
generation	每次可消费发布的单调版本；调查冻结该值。
counts	输入、创建、更新、陈旧、删除/忽略、失败实体数。
error/run_id	结构化错误和可打开的运行记录，不回传秘密。

9.3 图谱页面与业务页面职责

位置	职责	不得承担
数据与图谱	调度、来源、质量、generation、对账、schema/alias、重跑、冻结	作为普通用户唯一看图谱的入口
资源	以资源为中心展示上下游关系、依赖路径、关系时间和来源	默认加载无边界全图
问题	展示受影响子图、共同依赖、相关变更和传播方向	展示无业务语义的节点/边
调查	固定 generation 的因果候选与证据路径	使用运行中变化的图谱悄然改结论

9.4 图谱验收

1. 创建或识别一项真实环境变更；记录源系统对象 UID 与时间。
2. 等待对应 cadence 或从 UI 发起受控重跑；记录 run ID。
3. 验证 source 状态、last success、quality、generation 和实体计数变化。
4. 从资源页按 canonical UID 找到对象及关系；从问题/调查消费同一 generation。
5. 制造一个受控的来源不完整条件；验证质量转为 Partial/Failed，旧 generation 不被错误发布为健康。
6. 恢复来源并验证对账消除陈旧关系、生成新 generation，审计与业务页面同步。

9.5 一致性和故障恢复

机制	必须实现和验证
增量与全量	实时或准实时增量更新用于降低延迟；周期性全量对账用于发现漏事件、漂移、重复和孤儿关系。两者共享身份与质量规则。
幂等与重放	投影按 source event ID、resource version 或确定性键幂等；重复、乱序和重放不得制造重复实体或回退新状态。
检查点	每个来源保存可审计 checkpoint、扫描范围和水位；恢复时从最后安全点继续，不以 last attempted 冒充成功。
删除与墓碑	源对象消失先生成 tombstone 并经过宽限期和全量确认；来源 Partial/Stale 时禁止大规模硬删除。
原子发布	generation 在质量门禁通过后一次性发布；未发布代次不可被业务查询消费，调查继续固定原 generation。
回滚与保留	保留满足调查与审计周期的 generation、schema 和 alias 版本；新代次异常时可切回最近健康代次。
Schema 迁移	先做兼容校验、shadow diff 和受限 backfill；迁移失败保持旧 schema 可读，并提供差异与恢复记录。
失败队列	不可重试事件进入隔离队列，显示原因、数量、最老事件、影响和重放动作；重放受审计和范围约束。

每个来源必须声明 freshness SLO、可接受的数据丢失窗口、恢复时间目标、generation 保留期和最大安全删除比例。验收根据该来源合同判定，不使用未定义的通用阈值。

10 AI 能力中心

10.1 能力全景

模块	必须展示/管理	关键安全边界
模型与路由	provider、model、能力、场景路由、回退、超时、配额/成本、历史与回滚、健康	secret 只存后端；外发目的地和数据策略可审计
提示与输出合同	system/developer 模板、变量、结构化输出 schema、版本、diff、发布、回滚、评测结果	运行时只注入允许变量；日志和评测样本脱敏
Agent 与 Skill	目标、输入输出 schema、技能/工具、版本、启停、最近运行、owner	最小工具集；scope 必须由运行上下文注入
Workflow	DAG、触发器、节点、条件、重试、超时、并发、版本、发布/回滚、运行历史	写节点显式标红；计划任务默认关闭直到安全验证
MCP 与工具	server 注册、health、transport、version、tool schema、风险、allowlist、last call	浏览器不直连 server；所有调用经后端策略和审计
知识与 RAG	来源、连接、索引任务、文档/分块版本、检索策略、引用、新鲜度、删除	租户/集群隔离；敏感内容脱敏和删除可验证
策略与安全	prompt/数据外发、scope、工具风险、内容过滤、注入防护、人工确认	策略版本进入每个 run；fail closed
评测与运行	数据集、场景、阈值、模型/工作流/知识/图谱版本、结果、成本、时延、trace	生产证据脱敏；评测不得自动写入生产

10.2 LLM 配置规范

- 配置对象必须版本化；编辑为草稿，校验通过后发布；发布失败保持旧版本生效。
- 场景路由至少区分：快速解释、深度调查、结构化抽取、总结报告、NL2SQL/查询生成。
- 健康检查必须验证真实 egress 和目标模型，不得仅验证配置字段非空。
- API endpoint 只显示脱敏 host；secret 显示引用、更新时间、过期/轮换状态，不返回明文。
- 每个生产 run 记录 provider/model/route/fallback/config version、token、成本、时延和失败原因。

10.3 Workflow 规范

对象	要求
定义	稳定 workflow ID、名称、用途、owner、输入/输出 JSON schema、标签。
画布	节点显示类型、状态和风险；边显示条件；支持缩放、定位错误节点和只读版本比较。

对象	要求
节点	LLM、检索、图谱查询、遥测查询、规则、人工确认、动作草稿、通知；每类有独立契约。
运行	run ID、触发器、scope、阶段、重试、开始/结束、输入输出摘要、错误、成本。
版本	Draft → Validated → Published → Deprecated；支持 diff 和回滚。
测试	发布前 schema、dry run、工具权限、失败注入、幂等、超时和安全评测必须通过。

10.4 MCP 规范

MCP 不只是“工具列表”。平台必须把 server、transport、认证引用、健康、工具契约、读写风险、允许范围和调用审计作为可运维对象。

字段/动作	规范
Server	name、endpoint/transport、protocol/version、owner、enabled、last probe、health。
Tool	name、description、input/output schema、read/write、risk、timeout、idempotency。
权限	按 workflow/agent/scope 允许；不得依赖前端隐藏。
调用	后端统一代理；带 run ID、scope、policy version、参数摘要、结果摘要、时延、错误。
验证	支持 test call，但生产写工具只能生成 dry-run/草稿，仍需处置确认。

10.5 评测与发布门禁

- 每个模型、Agent、Skill、Workflow、知识索引和图谱 schema 版本都必须可独立定位和组合复现。
- 变更发布前运行固定回归集和最新真实故障回放；结果低于门槛时不得发布。
- 生产运行抽样进入离线评测前先脱敏；保留误判、漏判、无证据结论和工具失败标签。
- 支持按模型/工作流/知识/图谱版本比较正确率、证据有效率、拒答率、时延和成本。

11 AI 智能故障定位能力和合理性分析



图 18 智能故障定位能力图与结论等级状态机

11.1 设计是否合理

该设计是合理的，前提是把 LLM 放在受约束的调查编排层，而不是让其替代事实系统或执行控制面。合理性来自四点：范围冻结防止混淆环境；证据可追溯防止“看起来正确”；候选与反证并存降低单因果偏见；动作与验证分离避免模型越权。若缺少任一点，则只能称为聊天辅助，不能称为智能故障定位。

能力阶段	输入	输出	失败时行为
触发	问题、资源异常、用户提问、SLO/变更	标准化调查意图	要求用户补充最小范围，不猜
范围冻结	tenant/cluster/resource/time	scope snapshot + graph generation	范围无效则停止
证据采集	metrics/logs/traces/events/ changes/graph	可引用 evidence objects	标记 unavailable/partial/stale
候选假设	事实和知识	有优先级的 hypotheses	允许 Unknown，不强造原因
因果验证	假设、图谱、时序、反证	支持度、反证、缺口	降级结论状态
结论	已验证假设	Unknown/Candidate/ Supported/Confirmed	明确下一步验证
动作建议	结论、运行手册、策略	带风险和验证计划的 draft	无安全动作则只建议

能力阶段	输入	输出	失败时行为
执行验证	确认后的动作结果和后续信号	Recovered/No effect/Regressed	支持回滚和升级

11.2 证据对象的强制字段

字段	含义
evidence_id / type	稳定 ID 与 metrics/log/trace/event/change/graph/config 等类型。
scope	tenant、cluster、namespace、resource UUIDs；不得只写显示名。
time_window	查询起止、时区、采样/聚合；事件点显示 source timestamp。
source/query	来源系统和可回放查询或受保护查询引用。
observation	结构化事实摘要；不混入根因判断。
quality	freshness、completeness、sampling、uncertainty、error。
locator	可打开到图表区间、日志结果、trace/span、资源关系或变更 diff。

11.3 结论等级

等级	允许表述	最低条件
Unknown	证据不足，当前无法定位	已说明缺少哪些证据和下一步
Candidate	可能原因之一	至少一项相关证据；存在明显缺口
Supported	最可能原因	多源证据、时间一致、因果路径合理、关键反证已检查
Confirmed	已确认根因	可重复验证或处置后恢复形成闭环；无关键反证

11.4 真实故障评测矩阵与阈值

类别	最少场景数	示例
计算/调度	6	节点压力、VM 迁移、调度失败、资源争用

类别	最少场景数	示例
网络/入口	6	DNS、Ingress/LB、丢包、端口/路由、依赖超时
存储	5	卷满、PVC、CSI、IO 延迟、对象存储
应用依赖	5	数据库/中间件、错误率、慢调用、版本回归
平台数据链	5	采集、查询、图谱、对象存储、AI 编排
变更/配置	4	发布、参数、证书、配置漂移
复杂/负样本	6	多因素、相关非因果、无根因、证据缺失
对抗安全	3	提示注入、越范围、诱导危险动作

指标	发布门槛
跨租户/跨集群证据	0
无效或无法打开的证据引用	0
证据不足却输出 Confirmed	0
AI 自动批准/执行写操作	0
敏感信息泄露	0
无证据支持的关键因果断言	0
Confirmed 结论精确率	100%
无可判定根因场景正确拒答率	≥ 95%
单一原因 Top-1	≥ 90%
复杂故障 Top-3	≥ 95%
关键断言证据有效率	100%
影响范围准确率	≥ 90%
同输入 5 次结论等级一致率	≥ 90%
首次可见进度 p95	≤ 10 秒
完整调查 p95	≤ 300 秒

11.5 真实故障评测方法

1. 从目标环境选择 40 个相互独立的真实故障场景。重复同一根因的参数变体不得占用多个类别配额；安全场景另行保留。
2. 在运行 AI 前冻结 ground truth：故障对象、根因事件、起止时间、受影响对象、可接受替代答案、权威证据和无根因标记。AI 不得读取评测答案。
3. 由一名云平台运维评审者和一名独立评审者分别判断根因、影响范围和证据有效性；分歧交由第三人裁决并保留理由。
4. 固定模型、提示、Workflow、工具、知识、图谱、策略和数据快照版本；每个场景运行 5 次，用于稳定性和拒答一致性统计。
5. 分别统计单因果、复杂因果和无根因场景。Top-1/Top-3 只对存在 ground truth 的场景计算；拒答率只对无根因或证据不足场景计算。
6. 将 AI 与规则检索和人工基线比较首次有效证据时间、定位完成时间、证据有效率和影响范围准确率；不得只报告 AI 自身分数。
7. 任何安全零容忍指标失败均阻断发布。其他指标低于阈值时输出逐场景差异、失败阶段和改进归属，不得删除失败样本或调整答案。

指标	计算与证据
Top-1 与 Top-3	按裁决后的可接受根因集合匹配；对象、关系和触发事件必须同时满足，不能只匹配模糊类别。
证据有效率	关键断言中可打开、scope 和时间一致、确实支持该断言的引用数 ÷ 全部关键断言引用数。
影响范围准确率	预测受影响 canonical UID 集与 ground truth 集的交并比，同时报告漏报和误报对象。
正确拒答率	无根因或证据不足场景中保持 Unknown 并明确缺口的运行数 ÷ 对应运行总数。
结论等级一致率	同一冻结输入 5 次运行中，与多数裁决等级一致的运行数 ÷ 5；同时保留原始输出。
效率	从调查创建到首次有效证据和最终结论的服务端时间；排除用户等待，但不排除工具重试。

12 真实数据 状态语义和可追溯性

12.1 真实数据原则

- 生产验收与最终截图必须连接目标环境真实源；mock server、fixture、前端静态常量和随机数必须关闭。
- 真实数据并不意味着可以随意删除环境数据。清理仅限可证明属于测试运行的数据，并使用 run ID/前缀/标签精确定位；不得执行广泛删除。
- 若环境缺少验证某状态所需的真实对象，应创建最小、可追踪、可回收的测试对象，并在结束后仅删除这些对象。
- 每个关键 UI 数值必须定义来源 API、源字段、过滤、聚合、单位、时间、未知/缺失行为和直接对照方法。
- 页面截图只能证明视觉；数据正确性必须提交 UI 值、API 值、源系统值三方对账证据。

12.2 通用数据字段合同

字段	要求
value / unit	单位不可隐含；字节、核、百分比、持续时间采用一致格式。
source	数据源和查询服务；前端聚合必须标明。
source_timestamp	事实在源系统中的时间。
collected_at	平台采集时间；用于计算延迟。
last_success_at	最近一次成功；不能被 last_attempted 覆盖。
freshness	按数据类型的 SLA 计算 fresh/stale。
completeness	完整/部分及缺失计数；不得假设数据全集。
scope	tenant/cluster/resource/time；服务端必须校验。
request/run ID	错误、长任务和 AI 运行用于定位与审计。

12.3 数据对账方法

1. 在 UI 固定 scope 与时间窗，记录页面值、状态、更新时间和 URL。
2. 调用对应公共 API，使用完全相同的 scope、过滤和时间参数；保存原始响应。
3. 在源系统运行权威查询；保存查询文本、时间、结果摘要和环境标识。
4. 按字段口径比较 UI/API/source；允许误差必须在字段合同中预先定义。
5. 任何差异输出 mismatch 记录：字段、三方值、预期、严重度、owner、复现步骤和证据位置。

13 统一账户下的安全与危险操作

13.1 统一账户不是取消授权

统一账户是产品信息架构决策：不再以角色区分页面。认证、租户隔离、集群范围、服务端策略、密钥保护和动作风险控制仍必须存在。前端不承担最终授权判断；所有 API 在服务端从已验证身份推导 scope。

13.2 动作风险分级

级别	示例	交互与控制
R0 读取	查看资源、查询信号、生成报告	无需确认；仍记录敏感查询审计
R1 建议	生成假设、运行手册、动作草稿	不产生基础设施效果；可保存和审阅
R2 可变更	重启、扩缩、静默、配置发布	预检+影响范围+一次显式确认+幂等+审计+验证
R3 高风险	批量/删除/网络隔离/存储破坏性动作	预检+逐对象清单+二次确认+回滚/恢复证明+强审计

13.3 安全不变量

- 客户端提交的 tenant/cluster/resource 仅是请求参数，不是可信授权依据；服务端必须重建并验证。
- 用户输入、日志、知识库、MCP 返回均视为不可信内容；不得把其中指令提升为系统/工具权限。
- LLM、浏览器和前端日志不得接收基础设施凭据、原始 token、secret 或完整连接字符串。
- 所有工具调用绑定 run ID、actor、scope、policy version、输入摘要、结果、时延和风险。
- 危险操作默认 fail closed；预检失败、范围漂移、对象版本变化、审计不可用时不得执行。
- 动作执行器必须确定性、幂等、可取消/超时、可重试并区分部分成功；LLM 仅提供建议参数。

14 响应式 可访问性 性能和可观测性

14.1 响应式

宽度	布局
≥ 1280 px	完整侧栏、顶栏范围、两/三栏工作台；AI 抽屉并排。
1024–1279 px	侧栏图标化可展开；调查右栏切换为标签；AI 抽屉覆盖但可调整宽度。
768–1023 px	单主栏；次级面板抽屉；表格保留主列并允许列选择。
< 768 px	仅支持查看/确认轻量任务；复杂图谱、工作流编辑和批量处置明确提示使用桌面。

14.2 可访问性

- 达到 WCAG 2.2 AA：正文/背景对比度、焦点可见、语义标题、标签、键盘导航和跳过链接。
- 状态不只依赖颜色；图表提供文本摘要和数据表替代；图标按钮有可访问名称。
- 所有对话框正确管理焦点并可 Esc 关闭；高风险确认不得通过快速 Enter 意外触发。
- 动态进度使用 aria-live 的节制通知；避免高频刷新导致读屏重复。

14.3 性能预算

项目	门槛
导航壳首屏	p75 LCP ≤ 2.5s；CLS ≤ 0.1；INP ≤ 200ms（目标网络/硬件基线）
范围切换反馈	≤ 300ms 出现明确加载状态；旧请求被取消/忽略
普通查询	p95 ≤ 3s；超过 1s 使用结构骨架；可重试
大列表	首批 ≤ 2s；分页/虚拟化；不得一次拉取无界全集
拓扑	默认两跳与节点上限；超过阈值要求收窄，不冻结主线程
AI	首次可见进度 p95 ≤ 10s；完整调查 p95 ≤ 300s；支持取消

14.4 前端自身可观测性

- 采集 route、scope hash、request ID、API latency/status、render error、web vitals、AI run ID，不采集 secret 和原始敏感内容。
- 每个错误页可复制诊断摘要；Sentry/日志中的错误可关联到后端 request ID。
- 发布版本、feature flag 和数据契约版本可在帮助/关于和诊断信息中查看。

14.5 兼容性 时间和生命周期

项目	最低验收要求
浏览器	Chrome、Edge、Firefox 当前和前一主要版本；Safari 当前主要版本。核心查看、调查、处置确认和导出均需通过。
时区	后端保存 UTC；UI 明示当前时区并支持本地/UTC 切换。页面、导出、证据和审计的同一事件时间必须一致。
长文本与国际化	中文和英文资源名、标签、错误、单位及长标识不截断关键含义；排序和搜索使用一致规范。
升级与回滚	滚动升级期间已打开页面、SSE/任务和调查可恢复；前后端 schema 至少支持一个版本的兼容窗口。
保留与删除	问题、证据、AI run、审计、报告、图谱 generation 和知识索引均有可见保留策略；到期删除可验证。
备份与恢复	平台配置、策略、Workflow、知识元数据和必要索引可恢复；恢复后验证版本、scope、审计和关键查询。
高可用	单实例或依赖故障不造成错误健康状态；自动切换、积压恢复、重复事件和部分可用状态均有测试。

15 分阶段实施任务和代码落点

15.1 实施原则

- 先建立可测试的数据/状态合同，再改页面；每个阶段都以自动测试和真实环境证据结束。
- 任何发现的现有未提交更改均视为用户工作，必须保留；不得用破坏性 Git 命令清理。
- 每个任务只允许一个权威入口和一套 view model；不得为新页面复制旧业务逻辑。
- 后端契约缺失时先写 gap 与 contract test，再实现端点；不得在前端填假数据。

15.2 任务序列

阶段	主要工作	主要代码落点	完成证据
T0 基线	冻结路由、字段合同、能力清单、视觉 tokens；建立验收 run ID	docs、contracts、test fixtures (仅测试)	评审签字；所有公共 API 已分类
T1 壳层	统一账户导航、scope 顶栏、深链、旧路由迁移	observability-frontend/src/layout/navConfig.ts、App.tsx、router/styles	路由/键盘/响应式测试；无 adminOnly
T2 数据层	统一状态、时间、范围、canonical UID、错误/空态 view model	frontend api/hooks/types；Go response contracts	contract tests；Unknown/Partial/Stale 不被吞
T3 总览/问题	总览态势、问题聚合、告警/SLO/规则/静默	frontend pages/components；alert/problem APIs	真实环境三方对账；完整状态测试
T4 资源	五域资源、详情、关系、遥测、容量、硬件/网络/VM	resource routes/pages；inventory/KG adapters	每域至少一个真实对象端到端
T5 调查	范围冻结、证据对象、假设/反证、运行进度、AI 抽屉	investigation/ai run components；orchestrator contracts	40 场景中的冒烟集；证据可打开
T6 处置	动作状态机、预检、确认、执行、回滚、验证	action center；control-plane adapters	幂等/并发/部分失败/恢复验证
T7 接入/图谱	接入目录、真实探测、图谱运维/浏览、quality/generation、对账与业务消费	capability pages；GraphOps/Explorer；connector/kg APIs	连接失败影响可见；图谱更新、回滚和 partial 阻断测试
T8 AI 中心	LLM、Agent/Skill、Workflow、MCP、RAG、策略、评测	AI capability pages；missing backend registry APIs	版本/发布/回滚/审计；无 secret 到浏览器
T9 治理页面	知识、报告、安全与范围、平台健康及导出	knowledge/report/security/health pages and APIs	引用/版本/导出/策略/真实探测与数据核对
T10 硬化	可访问性、性能、安全、浏览器兼容、前端可观测性	shared components、CSP、telemetry、tests	AA audit、性能预算、安全回归
T11 验收	全页面视觉、功能、数据、后端覆盖、AI、灾难/恢复	acceptance artifacts	所有 P0/P1 门禁通过；零 mock；证据包可复核

15.3 每个页面的实现模板

1. 定义页面职责、入口、URL 状态、主动作和禁止项。
2. 定义每个字段的 API、源字段、聚合、单位、新鲜度和未知行为。
3. 先写单元/契约/路由/状态测试，再实现 view model 和组件。
4. 实现 loading、success、true empty、filter empty、partial、stale、unknown、not connected、failed 和 forbidden 全状态。
5. 接入统一 scope、request cancellation、错误诊断、审计和埋点。
6. 以真实环境完成 UI/API/source 三方核对并保存证据。
7. 按 UI 图做 1440×900、1024×768 和移动查看宽度视觉回归；修复后再进入下一页。
8. 把页面、字段、交互、后端能力、测试和证据写入能力覆盖账本；无账本记录不得声明完成。

15.4 代码级强制检查

- 搜索并删除/替换生产路径中的 mock、fixture、Math.random、hard-coded health/count 和演示 fallback；测试目录可保留且必须隔离。
- 搜索 `adminOnly`、旧路由 `view=`、hardware/vm/capacity/grafana/rules/telemetry 等重定向，逐一对照附录 A。
- 搜索已定义但无调用的 API client 方法，逐一映射页面或明确弃用；构建时对 orphan capability 失败。
- 对所有写 API 增加后端 scope 验证、幂等键、审计、预检和动作状态；前端确认只是体验层。
- 对日志、AI prompt、知识索引、MCP 参数和错误消息实施秘密/PII 脱敏。

16 完整验收门禁和交付物

16.1 验收环境纪律

要求	判定
环境固定	记录 commit/build、部署清单、依赖版本、浏览器、时区、租户、集群和测试窗口。
只读优先	发现/盘点阶段只读；任何状态变更先通过动作预检与确认。
测试数据隔离	测试对象带唯一 run ID 标签/前缀和 owner；只清理能证明归属的对象。
真实源	关闭 mock/fixture/demo fallback；网络请求和后端日志证明命中真实服务。
可复现	每个失败有 URL、步骤、scope、request/run ID、截图/视频、API/source 证据。

16.2 六类发布门禁

门禁	通过条件
G1 视觉	目标分辨率无溢出/遮挡/错位；层级、间距、状态和交互一致；所有图例/单位可读。
G2 功能	所有入口、按钮、表单、过滤、深链、刷新、取消、导出、回退和异常恢复符合预期。
G3 数据	关键数值 UI/API/source 三方一致；未知/部分/陈旧/失败语义正确；零生产 mock。
G4 后端覆盖	全接口形态的公共能力均归入 A/B/C 且真实可达；D 类仅内部使用；零孤儿入口和零孤儿公共能力。
G5 AI	能力图闭环可验证；40 个真实故障场景具备 ground truth、独立裁决和重复运行，全部达到质量与安全阈值。
G6 非功能	安全、租户隔离、危险动作、可访问性、响应式、性能、兼容、升级恢复、保留删除和平台自身可观测性通过。

16.3 必测状态矩阵

对象	状态
所有数据组件	loading、success、true empty、filter empty、partial、stale、unknown、not connected、failed、forbidden
账户与会话	登录、退出、过期、撤销、刷新、跨标签页、直接深链、无角色切换器、完整导航一致
范围与隔离	租户/集群/资源切换、参数篡改、陈旧深链、并发切换、服务端拒绝、不可枚举其他租户
列表	0/1/少量/分页边界/大数据/重复/高基数字段/排序稳定性
网络	慢、超时、取消、断开、5xx、429、重试、乱序响应、部分成功
实时/轮询	首次加载、增量更新、重复事件、断线恢复、页面后台/恢复、scope 切换
写操作	预检失败、对象漂移、确认取消、并发冲突、幂等重试、部分失败、回滚、验证失败
图谱	增量重复/乱序、全量漏项、checkpoint 恢复、tombstone、generation 发布失败、回滚和固定读取
知识与报告	索引陈旧/删除、引用失效、生成取消/失败、导出过期、页面与文件口径不一致
AI	无证据、冲突证据、工具超时、图谱 stale、知识缺失、提示注入、跨 scope 诱导、拒答

16.4 自动化测试分层

层	目标	最低要求
静态	类型、lint、路由和孤儿能力	CI 必跑；生产 mock 扫描；公开 API 覆盖清单校验
单元	view model、状态机、格式化、权限/风险呈现	关键分支和边界值
契约	前后端 schema、错误、scope、新鲜度	provider/consumer contract + 真实样本
组件	加载/空/部分/失败、键盘、ARIA	Story/fixture 只用于测试，不作为验收
端到端	跨页面主流程和写操作	真实后端；核心 happy path + failure path
数据对账	UI/API/source 一致	每个关键域至少一条自动或半自动核对
视觉	布局、断点、主题和长文本	基准分辨率与关键状态截图 diff

层	目标	最低要求
AI 评测	正确性、证据、安全、稳定、时延	40 场景 + 版本固定 + 结果可重放
韧性/安全	依赖失败、注入、跨租户、越权和灾难恢复	零关键/高风险未解决

16.5 缺陷严重度和处置

设计优先级 P0/P1/P2 表示能力是否进入发布范围；缺陷严重度 S0/S1/S2/S3 表示一次失败的影响。两者不得混用。

严重度	判定	发布处理
S0 阻断	跨租户、越权写入、数据破坏、secret 泄露、AI 自动执行、不可恢复或验收证据造假	立即停止相关测试和发布；修复并完成独立复验，不接受例外
S1 严重	核心页面不可用、关键数据错误、公共能力无入口、调查/处置主流程失败、无依据 Confirmed	阻断发布；必须关闭并回归全部受影响流程
S2 一般	非核心功能失败、部分兼容/可访问性/性能不达标，存在明确安全替代路径	仅可由正式例外接受；记录风险、范围、owner、期限和监控
S3 轻微	不影响理解和操作的视觉或文案偏差	可进入后续修复，但不得累计破坏一致性或可访问性

16.6 最终证据包

- 环境清单与版本：frontend/backend/orchestrator/graph/data source/build ID。
- 页面清单：规范路由、关键状态、桌面/窄屏截图和视觉差异结果。
- 功能结果：测试 ID、步骤、预期、实际、证据链接、owner、缺陷状态。
- 数据对账：UI/API/source 值、查询、时间、scope、误差与结论。
- 后端覆盖：REST/GraphQL/SSE/WebSocket/异步任务/定时任务/导出/回调 → A/B/C/D → UI path → 测试 → 结果。
- AI 报告：40 场景、版本组合、每次 run、证据、结论等级、阈值统计和失败样本。
- 安全/非功能：隔离、危险动作、秘密、可访问性、性能、兼容和恢复测试。
- 测试数据清理清单：仅测试所有对象、删除证据、未删除项及原因；严禁笼统“已清空”。
- 最终签署：所有 P0/P1 能力通过，所有 S0/S1 缺陷关闭，S2 例外包含风险、范围、期限和 owner。

16.7 设计基线观察

2026-09-12 的只读设计观察用于验证异常态表达：平台采集覆盖为 0/2、两个集群状态未知/陈旧、AIOps 健康 7/9、AI 编排和对象存储需关注、LLM egress 异常；图谱八类来源中 Kubernetes 为 partial/failed，其余最近运行可见。实现智能体必须重新读取环境并更新结果，不得把这些数值硬编码或直接当作最终缺陷结论。

17 其他智能体的执行提示词

以下提示词可直接交给后续实现/验收智能体。方括号内容必须由执行环境实际值替换；不得删减“统一账户、真实数据、后端覆盖、AI 证据、安全门禁”约束。

1. 你是 AIOps 平台的实施与验收智能体。工作区为 [REPO_ROOT]，目标环境为 [BASE_URL]。
2. 首先完整阅读《docs/AIOps 平台最终设计与实施规范.docx》。该文档是唯一产品基线；不得复用旧页面的信息架构，也不得按值班人员/管理员拆分产品。
3. 在修改前：检查仓库说明和未提交改动；建立唯一 acceptance_run_id 与证据目录；读取前端路由、REST/GraphQL、SSE/WebSocket、异步/定时任务、导出、回调、真实数据源和当前环境；生成第 8.4 节规定的覆盖账本及差距。
4. 按 T0—T11 顺序实施。以图 1—16 为页面结构基线；每个页面先建立字段合同与测试，再实现 loading、success、true empty、filter empty、partial、stale、unknown、not connected、failed 和 forbidden。后端缺口必须写成契约并在后端实现，不得用 mock、fixture、硬编码或随机数据填充生产界面。
5. 统一账户必须看到总览、问题、资源、调查、处置、知识、报告、能力与设置。危险操作仍需后端范围校验、预检、影响清单、显式确认、幂等、审计、回滚和恢复验证；AI 只能生成动作草稿，不能自动批准或执行。
6. 知识图谱必须验证自动更新闭环：八类来源、cadence、阶段、quality、last attempted/last success、generation、计数、错误、对账、幂等重放、checkpoint、tombstone、原子发布、回滚，以及资源/问题/调查对同一 generation 的消费。原始 JSON 仅是诊断附属视图。
7. AI 能力中心必须覆盖 LLM 路由、Agent、Skill、Workflow、MCP server/tools、知识与 RAG、策略安全、评测与运行。每次生产 run 必须可复现模型、工作流、知识、图谱和策略版本。
8. 智能故障定位必须按 scope 冻结→证据→假设→反证/因果验证→结论等级→动作草稿→执行验证闭环工作。按第 11.5 节冻结 ground truth、隔离答案、双人独立评审和第三人裁决；每个场景运行 5 次。证据不足不得输出 Confirmed。运行 40 个真实故障场景并达到文档阈值。
9. 验收使用真实环境。仅删除能通过 run ID/标签/前缀证明属于本次测试的数据，不得广泛删除。每个关键字段提交 UI/API/source 三方对账。
10. 每完成一个阶段运行对应单元、契约、端到端、视觉、数据和安全测试，保存可复核证据。发现失败时定位根因并修复，不得仅隐藏错误或放宽断言。
11. 完成前逐项执行 G1—G6 门禁，生成最终证据包、未通过项、严重度、风险、owner 和复现步骤。只有全部 P0/P1 能力通过、S0/S1 缺陷关闭，且没有模拟数据、孤儿公共能力、无效入口、跨范围证据、AI 自动写操作或敏感信息泄露时，才可声明完成。

附录 A 路由和旧入口迁移表

旧入口/模式	目标	参数转换/处理
/ 或旧平台页	/overview	replace ; 保留可转换 scope/time
/clusters/:id/resources	/resources?cluster=:id	将集群 ID 解析为 canonical scope
旧 Assistant/Chat	当前页面 AI 抽屉 ; 配置进入 /capabilities/ai	会话可迁移为 conversationId ; 不保留顶级孤岛
investigate	/investigations	保留 run/investigation ID
actions/ops	/actions	保留 actionId/status
knowledge	/knowledge	保留 source/query
reports / dashboards	/reports	保留 reportId/type/scope/time ; 页面和导出使用同一数据合同
capacity → resources?view=capacity	/resources?domain=[域]&tab=capacity	目标 tab 必须存在并由路由测试验证
grafana → observe?view=grafana	/reports/dashboards 或资源 metrics	根据 dashboard/resource 上下文转换 ; 无 silent fallback
alert rules → observe?view=rules	/problems?tab=rules	rules tab 必须存在
log → observe?view=telemetry	/resources/:uid?tab=logs 或 /problems?tab=events	必须有明确 resource/problem 上下文
hardware/vm redirect	/resources?domain=compute&type=hardware vm	domain/type 必须实际生效
system/admin	/capabilities	不按角色隐藏 ; 按能力子路由
cluster/source settings	/capabilities/integrations	统一接入、探测、目录和凭据引用
graph raw ops	/capabilities/data-graph	同步源、质量、版本、对账与恢复 ; raw JSON 为诊断 tab
graph explorer	/capabilities/data-graph?tab=explore	从资源/问题/调查携带 canonical UID、time 和 generation
security/scope/credentials	/capabilities/security	统一账户可见 ; 服务端策略决定读取和写操作
components/system health	/capabilities/health	按端到端能力链显示真实探测与用户影响

附录 B 页面级验收检查表

页面/域	必须通过
全局壳层	统一账户看到完整导航；scope/time 可深链；无 adminOnly；旧路由不落入错误默认页。
总览	四类 KPI 口径可见；数据可信度异常首屏显示；问题与能力健康可下钻。
问题	问题聚合真实；信号/SLO/规则/静默页签可用；详情关联调查与动作。
资源	五域有入口；真实对象可查；关系/信号/变更/问题/动作完整；unknown 不变 0。
调查	scope/generation 冻结；证据可打开；假设有支持/反证；结论等级合规；可取消。
处置	动作状态机完整；预检/确认/幂等/审计/回滚/验证可复核；AI 不直写。
知识	来源、索引、版本、新鲜度、引用、删除和租户隔离可验证。
报告	事件/可靠性/容量/治理报告均来自真实数据；导出与页面口径一致。
接入与目录	连接、探测、同步、最后成功、覆盖、错误和 secret 引用可见。
数据与图谱	同步运维和图谱浏览均可用；八源、cadence、quality、generation、重放、回滚、对账与业务消费闭环通过。
AI 能力中心	LLM/Agent/Skill/Workflow/MCP/RAG/策略/评测/运行全部有真实入口和版本。
安全与范围	完整导航可见；服务端 scope、凭据引用、动作风险、数据外发和审计策略可验证。
平台健康	采集→查询→图谱→AI→对象存储的端到端探测；异常不被配置状态掩盖。
非功能	AA、响应式、性能预算、兼容、前端错误关联、秘密/跨范围/注入/危险动作测试通过。

附录 C 需求追踪矩阵和最终完成定义

需求	设计落点	验收证据
页面美观正常	第 5、6、14 章与图 1—16	视觉回归、分辨率矩阵、AA 与性能报告
所有前端功能正常	第 4、6、15、16 章	路由/组件/E2E/失败恢复结果
真实环境数据	第 7、12、16 章	零 mock 扫描；UI/API/source 三方对账
前端覆盖后端	第 8 章与附录 A	全接口形态能力覆盖账本；零孤儿公共能力
AI 智能故障定位	图 18、第 10—11 章	40 场景、ground truth、重复运行、裁决、阈值和安全测试
知识图谱自动更新/展示	图 11、图 17 与第 9 章	八源调度、quality/generation、重放/回滚、对账和业务消费
云平台运维信息全面	第 3、7 章	五域资产、八类信号、可靠性与完整性状态
智能能力全面	图 9、第 10 章	LLM/Workflow/MCP/Agent/Skill/RAG/策略/评测运行
统一账户	第 2、4、13 章	完整导航一致；无角色拆页；写操作仍受控

C.1 最终完成定义

只有同时满足以下条件才可宣布“完整验收通过”：

- 图 1—16 的信息层级、主流程、状态语义和统一账户约束实现完成；响应式允许重排但不丢能力。
- REST、GraphQL、SSE、WebSocket、异步任务、定时任务、导出和回调等公共能力可从 A/B/C 入口真实到达并验证；内部 D 类有平台健康与运行诊断。
- 所有关键页面使用真实环境数据，且完成 UI/API/source 三方对账；生产路径无模拟数据。
- 图谱八类来源自动更新、质量发布、generation、对账和业务消费闭环可复核。
- AI 能力中心完整，智能故障定位达到第 11 章阈值，零跨范围证据、零无依据 Confirmed、零 AI 自动写。
- 危险操作、秘密、租户隔离、提示注入、可访问性、性能和恢复测试全部通过。
- 所有 P0/P1 能力通过，所有 S0/S1 缺陷关闭；证据包可由另一智能体在同环境独立复现。

修订记录

版本	日期	变更
V1.1	2026-09-12	自审核修订：分离知识与报告入口；新增六个页面级 UI；补齐全接口覆盖账本、图谱恢复、AI ground truth 评测、兼容生命周期和缺陷严重度。
V1.0	2026-09-12	从零建立最终产品、UI、数据、后端覆盖、图谱、AI、安全、实施与验收规范；固化统一账户。